

Portada

Proyecto de Minería de Datos (Spotify 2023)

Gerardo Alonso González González

Minería de datos, Ingeniería Informática, Prof. Eliecer Peña Ancavil.

Fecha de Entrega: 16-04-2026

Contenido

Portada.....	1
Resumen Ejecutivo	2
1. Introducción	3
2. Metodología	3
3. Análisis de Datos.....	4
5. Conclusiones	7
6. Bibliografía.....	7

Resumen Ejecutivo

En este proyecto realicé la limpieza y el reemplazo de valores en el dataset de Spotify 2023. El objetivo principal fue solucionar el problema de los datos faltantes y transformar el contenido para que sea manejable por la computadora. Para lograrlo, realicé una limpieza de nulos usando la mediana en los números faltantes, ya que es mejor a la hora de tener datos muy alejados (outliers), mientras que en el caso del texto usé la moda para tener cálculos más realistas.

Como resultado de este proceso, logré la uniformidad de los datos; por ejemplo, al filtrar el rango de años de 2017 a 2023, los lanzamientos (released_year) quedaron con una desviación estándar de solo 1.22, lo que facilita mucho su estudio por la baja dispersión. El dataset quedó estandarizado y codificado, significando que todos los datos son del mismo tipo y pasé el texto a binarios (ceros y unos). Esto lo hice aplicando One-Hot Encoding para crear columnas de verdadero o falso para las notas musicales y Label Encoding para transformar las categorías, todo para que la computadora los pudiera trabajar de una manera más simple. En conclusión, el dataset ahora es totalmente funcional para realizar análisis precisos sobre las tendencias musicales.

1. Introducción

En el área de la música, el análisis de datos es esencial para entender por qué una canción es exitosa. En este proyecto, el propósito es aprender a transformar datos crudos en información útil, utilizando el dataset de Spotify 2023. Esto nos permite enfrentar problemas comunes como los valores nulos o los números demasiado alejados (outliers), los cuales impiden un cálculo estadístico correcto y demuestran la necesidad de aplicar técnicas de limpieza.

A través del análisis del dataset, se observa que existe una irregularidad en el conteo de datos y una gran dispersión en los valores de éxito (streams). Por ello, este estudio se plantea los siguientes objetivos:

-Aplicar técnicas de limpieza y transformación: Aprender a imputar valores nulos, tratar outliers mediante el método IQR y codificar variables categóricas reutilizando el pipeline de Malenia en este nuevo dataset.

-Dominar herramientas de análisis: Aprender a trabajar con Python dentro del entorno de Google Colab para automatizar tareas de ingeniería de datos.

-Generar resultados estandarizados: Obtener un dataset limpio y comprender cómo el uso de gráficos y estadísticas permite interpretar correctamente el comportamiento de canciones exitosas.

2. Metodología

El dataset Spotify 2023 (modificado) funciona como un catálogo de las canciones más exitosas, tiene datos clave como la cantidad de reproducciones (streams), el ritmo para bailar (danceability), la nota musical (key), el modo (mode), lo que hace diferente a este estudio del trabajo de Malenia es que cambiamos de ambiente, cambiando los videojuegos para enfocarnos totalmente en el mundo de la música.

Métodos Estadísticos Utilizados Para procesar esta información de forma fácil, usamos las herramientas Pandas, Seaborn y matplotlib, aplicando estos procesos:

-Técnicas de imputación: Rellenar los espacios vacíos, donde falta información, dependiendo el dato, usamos la media (el promedio), la mediana (el punto medio) para que los valores extremos no distorsionen los cálculos, o la moda (lo que más se repite) para los textos.

-Tratamiento de Outliers (IQR): Usamos el Rango Intercuartílico para detectar y limpiar esos números demasiado grandes que distorsionan los resultados.

-Codificación (Encoding): Usamos One Hot para crear opciones de sí o no (True o False) para las notas musicales, y Label Encoding para darles un numero binario (0 o 1).

-Visualización: Creamos representaciones visuales como histogramas (para ver qué tanto se repite un dato), boxplots (gráficos de caja) para ver si los datos están muy juntos o no, además de unas comparaciones para ver su comportamiento.

3. Análisis de Datos


Como se observa en la Tabla 1, Había una gran cantidad de valores atípicos en la columna de reproducciones, lo que movía a la media y aumentaba la desviación estándar (dispersión de los números), sesgando el análisis de las canciones.

Tabla 1. Resumen inicial del dataset.

df.describe()							
	released_year	released_month	released_day	in_spotify_playlists	streams	danceability_%	energy_%
count	952.000000	952.000000	952.000000	905.000000	9.520000e+02	905.000000	952.000000
mean	2018.288866	6.038866	13.944328	5273.350276	5.141374e+08	66.981215	64.274160
std	11.011397	3.564571	9.197223	7991.359501	5.668569e+08	14.700953	16.558517
min	1930.000000	1.000000	1.000000	31.000000	2.762000e+03	23.000000	9.000000
25%	2020.000000	3.000000	6.000000	870.000000	1.416362e+08	57.000000	53.000000
50%	2022.000000	6.000000	13.000000	2224.000000	2.905309e+08	69.000000	66.000000
75%	2022.000000	9.000000	22.000000	5730.000000	6.738690e+08	78.000000	77.000000
max	2023.000000	12.000000	31.000000	52898.000000	3.703895e+09	96.000000	97.000000

Tras realizar las operaciones de limpieza, la dispersión de la columna streams se redujo significativamente, pasando de 566 millones a 334 millones. Este cambio en la forma de los datos, donde la media y la mediana están ahora más cerca, se puede apreciar visualmente en la comparativa de la Figura 1 y Tabla 2, mostrando valores más compactos sobre el bigote superior y uniformidad de datos.

Figura 1 y Tabla 2. Visualización de la distribución de streams y resumen estadístico después de la limpieza.



	Tipo de dato	Cantidad de nulos	Media	Desv. Estandar	Mediana
danceability_%	float64	0	6.727000e+01	1.407000e+01	69.0
energy_%	int64	0	6.449000e+01	1.623000e+01	66.0
in_spotify_playlists	float64	0	2.640730e+03	2.434800e+03	2224.0
key	object	0	NaN	NaN	NaN
mode	object	0	NaN	NaN	NaN
released_day	int64	0	1.394000e+01	9.200000e+00	13.0
released_month	int64	0	6.040000e+00	3.560000e+00	6.0
released_year	int64	0	2.021700e+03	1.220000e+00	2022.0
streams	int64	0	3.790285e+08	3.341686e+08	290379770.5
track_name	object	0	NaN	NaN	NaN

Finalmente, para el manejo de variables categóricas, se aplicaron criterios de codificación distintos según el tipo de valor, como se muestra en la Tabla 3 y 4. Para la variable mode, se utilizó Label Encoding (0 y 1) dejándolo como binario. y para la variable key, se usó el One Hot Encoding (columnas de True o False) para evitar crear una jerarquía mala entre las canciones, asegurando que la computadora analicé patrones sin sesgos significativos.

Tabla 3. Muestra de datos originales con variables categóricas en texto.

	track_name	released_year	released_month	released_day	in_spotify_playlists	streams	key	mode
0	Seven (feat. Latto) (Explicit Ver.)	2023	7	14	553.0	141381703	B	Major
1	LALA	2023	3	23	1474.0	133716286	C#	Major
2	vampire	2023	6	30	1397.0	140003974	F	Major
3	Cruel Summer	2019	8	23	7858.0	800840817	A	Major
4	WHERE SHE GOES	2023	5	18	3133.0	303236322	A	Minor

Tabla 4. Resultado de la codificación mediante One Hot Encoding y Label Encoding.

mode	danceability_%	energy_%	key_A	key_A#	key_B	key_C#	key_D	key_D#	key_E	key_F	key_F#	key_G	key_G#
0	80.0	83	False	False	True	False	False	False	False	False	False	False	False
0	71.0	74	False	False	False	True	False	False	False	False	False	False	False
0	51.0	53	False	False	False	False	False	False	False	True	False	False	False
0	55.0	72	True	False	False	False	False	False	False	False	False	False	False
1	65.0	80	True	False	False	False	False	False	False	False	False	False	False

4. Discusión

Interpretación:

Al reducir los valores dispersos (streams), se confirmó que los outliers estaban cambiando mucho los datos, pero usar el IQR y la mediana fue mejor que la media porque evita que los valores tan extremos distorsionen los cálculos. En las categorías, usé One Hot Encoding para las notas musicales para que el computador las trabaje de forma independiente y más fácil, y Label Encoding (0 y 1) para el modo musical (Major o Minor) por ser solo dos opciones, esto nos dice que las canciones exitosas son difíciles de manejar por su magnitud y deben ser tratados con cuidado.

Limitaciones:

Lo principal fue el caso del released_year (con desviación estándar de 1.22), ya que al disminuir tantas fechas se limitó un análisis más histórico, además tuve problemas con columnas que tenían muchos espacios vacíos (nulos) y para esto tuve que documentar el dataset para entender mejor cada dato antes de procesarlo.

Mejoras:

Se podría usar otros datasets de música para comparar distintas codificaciones para ver cuál le sirve más al computador, además se podría intentar no recortar tanto el rango de años para ver si aparecen algunos patrones.

5. Conclusiones

Desde el inicio de esta investigación se detectaron una variedad de problemas, como la irregularidad en el conteo de los registros por el gran problema de los valores nulos. Debido a esto, utilizamos la imputación a través de la mediana, logrando estabilizar las columnas y eliminando esos espacios vacíos, lo que favorece las visualizaciones para futuras investigaciones.

El tratamiento de los valores alejados (outliers) fue de las partes más difíciles para mí, porque el manejo de datos es delicado y una mala ejecución afecta todo el análisis posterior, pero se pudo realizar de buena manera gracias al IQR, que ayudó a reducir la desviación estándar de la variable streams (de 566 millones a 334 millones). Este resultado nos dice que hay una mayor uniformidad en los datos, evitando que las canciones exitosas sesguen los cálculos, también al revisar los histogramas de las fechas, pude apreciar cómo la distribución del released_year se vuelve más simple al limpiarla.

Uno de los tratamientos finales, y para mí de los más interesantes, fue la transformación de variables categóricas (key y mode) a variables más fáciles de entender para la computadora. El One Hot Encoding para la columna key fue lo que más me llamó la atención al ser tan específico, permitiendo que cada nota musical se maneje de forma independiente con True o False.

Como resultado, se obtuvo un dataset limpio, codificado y uniforme, con una media y mediana más cercanas que al inicio, este proceso es fundamental porque nos enseña que, en la vida real, no puedes trabajar con datos sin un manejo previo, esto nos dice que necesitamos un orden para que los resultados sean verdaderos y el proyecto cumpla su objetivo, como se logró aquí.

6. Bibliografía

Kaggle. (2023). *Most Streamed Spotify Songs 2023*. Recuperado de <https://www.kaggle.com/datasets/nelgiriyeewithana/top-spotify-songs-2023>

Peña Ancavil, E. (2026). *Pipeline de procesamiento de datos: Caso Malenia*. Minería de Datos, Universidad Bernardo O'Higgins.

Pandas Development Team. (2026). *Pandas: Powerful data analysis toolkit*. Recuperado de <https://pandas.pydata.org/>

Waskom, M. L. (2021). *Seaborn: statistical data visualization*. Recuperado de <https://seaborn.pydata.org/>

Hunter, J. D. (2007). *Matplotlib: A 2D graphics environment*. Computing in Science & Engineering.